

# SVM (Support Vector Machine)


“두 집단을 구분하는 가장 넓은 도로”

하드 마진

- 모든 샘플이 도로 바깥쪽에 위치
- 이상치에 민감

소프트 마진

- 마진오류를 일부 허용
- 과대적합을 방지




# 하드 마진 Idea

결정 경계와 수직인 어떤 벡터  $w$

어떤 점에 대한 위치벡터  $u$

$u$ 를  $w$ 에 정사영한 벡터가 결정경계를  
(넘는다면 / 넘지 않는다면)

(positive / negative)로 분류



$w \cdot u \geq c$  이면 positive

$\Rightarrow w \cdot u + b \geq 0$  이면 positive “Decision Rule”

목표: 마진을 가장 크게 하는  $w$ 와  $b$  찾기

$w$ : 결정경계의 방향 결정,  $b$ : 결정경계의 위치 결정

# 마진 결정 (도로의 양 끝선)

positive:  $w \cdot x_+ + b \geq 1$

negative:  $w \cdot x_- + b \leq -1$


$t_i$  정의: I번째 샘플이

positive 일 때 1, negative 일 때 -1

$$t_i(w \cdot x_i + b) - 1 \geq 0$$

도로의 양 끝에 위치한 서포트 벡터의 경우

$$t_i(w \cdot x_i + b) - 1 = 0$$



# 마진의 너비


$x_+ - x_-$  벡터를  $w$  벡터에 정사영한 벡터의 길이

$$(x_+ - x_-) \cdot \frac{w}{\|w\|}$$

양 서포트 벡터  $x_+, x_-$ 에 대해

$t_i(w \cdot x_i + b) - 1 = 0$  에서

positive:  $t_i = 1$ 이고,  $w \cdot x_+ = 1 - b$  / negative:  $t_i = -1$ 이고,  $w \cdot x_- = 1 + b$



$$(x_+ - x_-) \cdot \frac{w}{\|w\|} = \frac{1}{\|w\|} (1 - b + 1 + b) = \frac{2}{\|w\|}$$

SVM 목표: 마진을 최대화

$$\sim \frac{2}{\|w\|} \text{ 최대화} \quad \sim \|w\| \text{ 최소화} \quad \sim \frac{1}{2} \|w\|^2 \text{ 최소화}$$

라그랑주 승수법

$g_i(x_1, \dots, x_n) = C_i$  ( $i = 1, \dots, k$ )의 제약조건에서  $f(x_1, \dots, x_n)$ 의 최소 조건

$$\nabla f = \sum_i \alpha_i \nabla g_i \Rightarrow \nabla f - \sum_i \alpha_i \nabla g_i = 0$$

$L = f - \sum_i \alpha_i g_i$  일 때,  $\nabla L = 0$  과 동일한 식

$t_i(w \cdot x_i + b) - 1 = 0$  의 제약조건에서  $\frac{1}{2} \|w\|^2$ 의 최소조건

$$L = \frac{1}{2} \|w\|^2 - \sum_i \alpha_i (t_i(w \cdot x_i + b) - 1) \text{ 에서}$$

$$\nabla_w L = w - \sum_i \alpha_i t_i x_i = 0 \quad \Rightarrow \quad w = \sum_i \alpha_i t_i x_i$$

$$\nabla_b L = -\sum_i \alpha_i t_i = 0 \quad \Rightarrow \quad \sum_i \alpha_i t_i = 0$$

두 결과를  $L$ 에 대입

$$L = \frac{1}{2} \left( \sum_i \alpha_i t_i x_i \right) \cdot \left( \sum_i \alpha_i t_i x_i \right) - \left( \sum_i \alpha_i t_i x_i \right) \cdot \left( \sum_i \alpha_i t_i x_i \right) - \sum_i \alpha_i t_i b + \sum_i \alpha_i$$

$$L = \sum_i \alpha_i - \frac{1}{2} \left( \sum_i \sum_j \alpha_i \alpha_j t_i t_j x_i \cdot x_j \right)$$

$$L = \sum_i \alpha_i - \frac{1}{2} \left( \sum_i \sum_j \alpha_i \alpha_j t_i t_j \mathbf{x}_i \cdot \mathbf{x}_j \right)$$

$\alpha$ ,  $t$ 는 모두 스칼라,  $L$ 은 내적  $\mathbf{x}_i \cdot \mathbf{x}_j$ 와 연관이 있다.

$t_i$ ,  $\mathbf{x}_i$ 는 주어진 값,  $L$ 은  $\alpha_i$ 에 대한 이차식

목적함수  $L$ : QP (Quadratic Programming)

$$L = \sum_i \alpha_i - \frac{1}{2} \left( \sum_i \sum_j \alpha_i \alpha_j t_i t_j \mathbf{x}_i \cdot \mathbf{x}_j \right) \text{ 를 최대화하고,}$$

모든 샘플에 대해  $\hat{\alpha}_i \geq 0$  이고,  $\sum_i \hat{\alpha}_i t_i = 0$  를 만족하는  $\hat{\alpha}$  찾기

$\hat{\alpha}$ 를 찾았다면

$$\hat{w} = \sum_i \hat{\alpha}_i t_i x_i$$

$$\hat{b} = \frac{1}{n_s} \sum_{\hat{\alpha}_i > 0} (t_i - \hat{w} \cdot x_i)$$

“목표: 마진을 가장 크게 하는  $w$ 와  $b$  찾기”



## 비선형 SVM

도호가 직선으로 결정되지 못하는 경우 샘플들의 공간을 변환

$$x \rightarrow \phi(x), \quad x_i \cdot x_j \rightarrow \phi(x_i) \cdot \phi(x_j)$$

## 커널 SVM

변환  $\phi$ 의 계산 없이 바로  $\phi(x_i) \cdot \phi(x_j)$ 를 구하는 커널, 계산복잡도의 이득

$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

$$\begin{aligned} \text{이 경우 } L &= \sum_i \alpha_i - \frac{1}{2} \left( \sum_i \sum_j \alpha_i \alpha_j t_i t_j \phi(x_i) \cdot \phi(x_j) \right) \\ &= \sum_i \alpha_i - \frac{1}{2} \left( \sum_i \sum_j \alpha_i \alpha_j t_i t_j K(x_i, x_j) \right) \end{aligned}$$

## 파이썬에서

- sklearn.svm의 LinearSVC
- sklearn.svm의 SVC
- sklearn.linear\_model의 SGDClassifier

라이브러리	알고리즘	커널 트릭	계산 복잡도
LinearSVC	목적 함수	불가능	$O(m \times n)$
SGDClassifier	확률적 경사하강법	불가능	$O(m \times n)$
SVC	목적 함수	가능	$O(m^2 \times n) \sim O(m^3 \times n)$

## 참고 자료

- 오헬리앙 제롱, *핸즈온 머신러닝 2판* (한빛미디어, 2020), 205-228, 887-889
- Patrick Winston, “16. Learning: Support Vector Machines” *MIT 6.034 Artificial Intelligence, Fall 2010*. last modified JAN 11, 2014,  
[https://youtu.be/\\_PwhiWxHK8o](https://youtu.be/_PwhiWxHK8o)